PulsEvents RAG

Un assistant qui recommande les événements de la métropole Aix-Marseille-Provence, à partir de l'agenda réel, sans rien inventer.

DONNÉES
4 294 événements Open Agenda

STACK
LangChain · Mistral · Faiss · FastAPI

LIVRAISON
v0.3.0 · image Docker

Répondre en langage naturel, à partir de notre agenda

Comprendre

« Un atelier d'immersion professionnelle à Aix dans les 15 prochains jours » : thème, ville, dates.

Trouver

Les événements réels de l'agenda, à jour, dans la bonne zone et la bonne période.

Répondre

Une réponse claire qui cite chaque événement (titre, date, lieu, lien), ou qui dit qu'il n'y a rien.

→ Livrer un POC : API REST, image Docker, qualité mesurée.

Comme un libraire : chercher d'abord, rédiger ensuite

Un modèle de langage seul ne connaît pas notre agenda et invente. Le RAG lui fournit les bons documents avant qu'il réponde.

1 · QUESTION

Comprendre

thème, communes, période

→

2 · RECHERCHE

Retrouver

par le sens, dans 4 854 passages

→

3 · RÉDACTION

Répondre

uniquement à partir des événements trouvés

→

RÉSULTAT

Réponse sourcée

chaque événement avec son lien

Tout l'agenda de la métropole, rafraîchi chaque jour

4 294

ÉVÉNEMENTS

365 derniers jours et à venir

92

COMMUNES

filtre par ville, alias (« Aix »)

24 h

FRAÎCHEUR

resynchronisation automatique

3 min

RECONSTRUCTION

puis seuls les nouveaux passages

`nettoyage HTML / Markdown` `découpage 1 000 car.` `mistral-embed · 1 024 dim.` `≈ 75 % emploi · 25 % culture`

Une chaîne simple, entièrement automatisée

SOURCE
Open Agenda
API v2, pagination

→

PRÉPARATION
Documents
nettoyage, découpage, métadonnées

→

INDEX
Faiss
vecteurs Mistral, manifeste

→

CHAÎNE
LangChain
filtres + LLM Mistral

→

ACCÈS
API FastAPI
/ask /metadata /health /rebuild

`image Docker avec index embarqué` `gate d'évaluation à chaque version` `un adaptateur LLM : vLLM local ou OpenRouter`

Rien à Aix ? Il le dit, et cherche autour

La question

« Je recherche un atelier d'immersion professionnelle à Aix-en-Provence dans les 15 prochains jours »

`thème : immersion pro` `Aix-en-Provence` `8 → 23 nov.`

La réponse

« Il n'y a aucun événement pertinent à Aix-en-Provence. Voici un événement situé aux alentours : **Atelier « Trouver et préparer son immersion professionnelle »**, jeudi 19 novembre, 08h45, agence Marseille Pont de Vivaux, à 28,1 km. »

→ Filtres exhaustifs, élargissement par rayons (5 → 40 km), distance annoncée.

Une vraie conversation, qui garde le contexte

VOUS « Les événements à Aix dans les 15 prochains jours ? »

IA 17 événements, surtout découverte des métiers, création d'entreprise, recrutement. Que recherchez-vous ?

outil list_event_themes · réponse affichée au fil de l'eau (streaming)

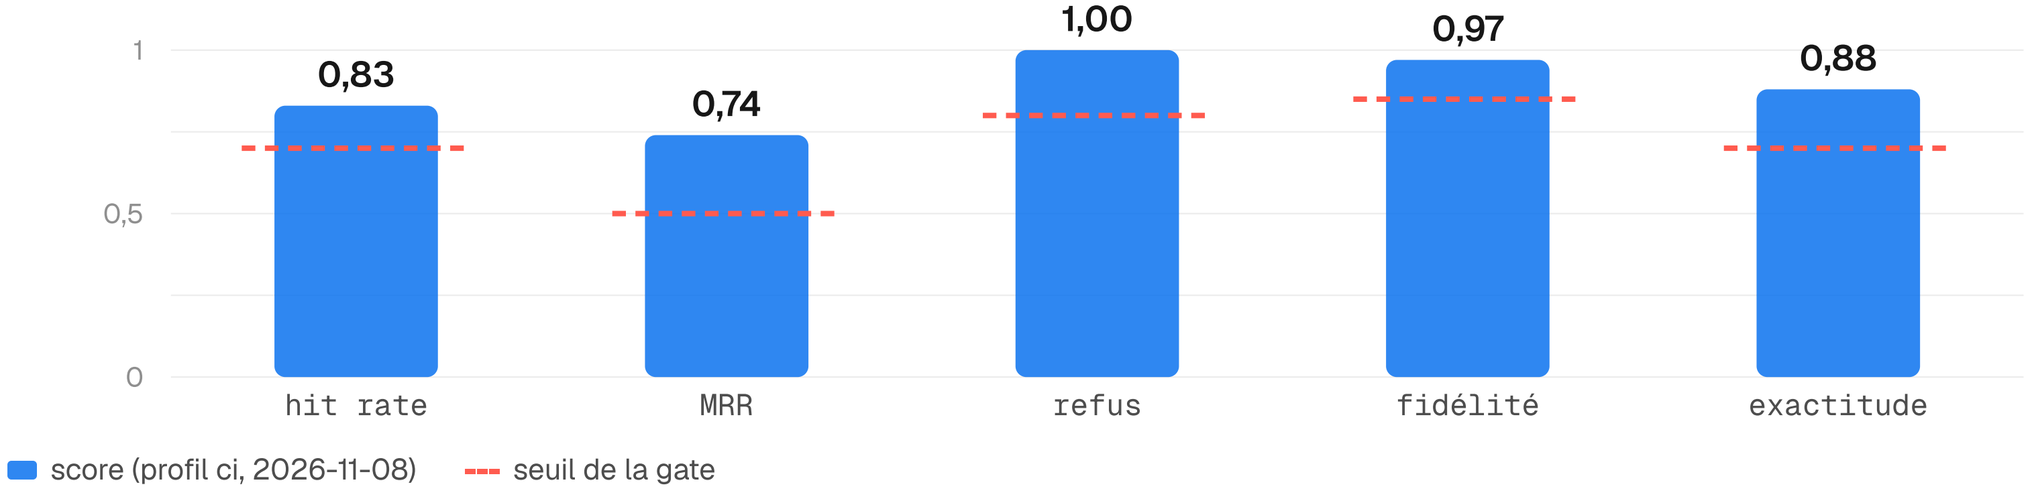
VOUS « Je recherche un atelier d'immersion professionnelle. »

IA Deux rendez-vous à Aix, les 18 et 20 novembre…

outil search_events · réutilise Aix et les dates sans les redemander

agent LangChain à outils | sessions par utilisateur (JWT) | historique persistant

40 questions annotées, cinq indicateurs



Thème, lieu, date, sans réponse, hors sujet, hors zone · LLM-juge structuré · bloque la release sous un seuil.

Hit rate : de 0,48 à 0,83

- **Le modèle inventait des villes et des dates**
  ancrage : on ne garde que ce que la question dit vraiment → 0,48 → 0,86

- **La distance sémantique seule ratait des titres évidents**
  recherche hybride : bonus lexical pondéré par la rareté des mots

- **Des propositions hors sujet « aux alentours »**
  seuil resserré pendant l'élargissement · seuil global calibré à 0,52

- **14 scénarios de robustesse : 14/14**
  injection de prompt, anglais, fautes d'orthographe, hors zone, sans résultat

Rapide à chercher, le LLM fait l'essentiel du temps

6 ms

RECHERCHE FILTRÉE

p50, sur tout l'index

≈ 5 s

RÉPONSE /ASK

p50 ; deux appels LLM

0,01 $

ÉVALUATION COMPLÈTE

40 questions, ≈ 30 s

92 %

COUVERTURE DE TESTS

145 tests sans réseau

Un conteneur, trois questions

01 **`docker compose up` · `GET /metadata`**
l'agenda complet est déjà dans l'image

02 **Immersion professionnelle à Aix, sous 15 jours**
filtres, élargissement, sources

03 **Spectacles au théâtre des Salins en décembre**
l'offre culturelle

04 **« Quel temps fera-t-il demain ? »**
il recentre au lieu de répondre à côté

05 **Fenêtre de chat et Swagger**
conversation multi-tour · API documentée

Un POC solide, des pistes claires

Limites

Agenda à 75 % emploi · seuil calibré sur cet agenda · ≈ 5 s par réponse · jeu annoté par une seule personne.

Qualité

Reranking des meilleurs candidats · filtres sur chaque date d'un événement · jeu d'évaluation élargi, juge indépendant.

Produit

Ajout d'un événement à l'agenda de l'utilisateur · réponses en streaming sur /ask · autres agendas, autres villes.

Production

Image publiée et scannée à chaque version · cache partagé (Valkey) · base PostgreSQL · observabilité (Langfuse).